

Prognozowanie kierunku kursu USD/PLN

Hybrydowy model LSTM + Transformer

Projekt z przedmiotu Sztuczna inteligencja

Dokumentacja

Jakub Jankowski

INFORMATYKA STOSOWANA
Semestr IV Grupa 1

Politechnika Bydgoska
im. Jana i Jędrzeja Śniadeckich w Bydgoszczy
Wydział Telekomunikacji, Informatyki i Elektrotechniki

Bydgoszcz, 2026

Spis treści

1	Wstęp	3
2	Teoria	6
2.1	Szeregi czasowe finansowe	6
2.2	Sieci LSTM	6
2.3	Architektura Transformer i mechanizm uwagi	6
2.4	Dane wejściowe modelu	6
2.4.1	Notowania walutowe (stopy zwrotu)	7
2.4.2	Momentum	7
2.4.3	Wskaźniki techniczne	7
2.4.4	Cechy z zakresu High/Low (USD/PLN)	7
2.4.5	Stopy procentowe banków centralnych	8
2.4.6	Opóźniony kierunek zmiany ceny	8
2.4.7	Preprocessing przed wejściem do sieci	8
2.5	Zadanie klasyfikacji binarnej	8
3	Opis działania aplikacji	9
3.1	Uwagi przed uruchomieniem	9
3.2	O aplikacji	9
3.3	Przepływ danych	9
3.4	Parametry konfiguracyjne	10
3.5	Architektura modelu	10
3.6	Interpretacja wyników	11
4	Badania modelu	12
4.1	Wprowadzenie	12
4.2	Konfiguracja bazowa	12
4.3	Wyniki konfiguracji bazowej	12
4.3.1	Macierz pomyłek	13
4.3.2	Metryki klasyfikacji i benchmark	13
4.3.3	Interpretacja wyników	13
4.4	Eksperymenty ze zmianą parametrów	13
4.5	Wyniki eksperymentów	14
4.5.1	E1 — wpływ <code>sliding_window</code>	14
4.5.2	E2 — wpływ <code>num_heads</code>	14
4.5.3	E3 — wpływ <code>learning rate</code>	14
4.5.4	E4 — wpływ <code>dropout</code>	15

5	Wnioski	16
5.1	Podsumowanie badań	16
5.2	Wnioski z poszczególnych eksperymentów	16
5.2.1	E1 — długość okna <code>sliding_window</code>	16
5.2.2	E2 — liczba głów uwagi <code>num_heads</code>	16
5.2.3	E3 — szybkość uczenia (learning rate)	16
5.2.4	E4 — współczynnik dropout	17
5.3	Wnioski ogólne	17
5.4	Ograniczenia	17
5.4.1	Repozytorium projektu	17

Rozdział 1

Wstęp

Rynek walutowy stanowi jeden z najbardziej płynnych i globalnie zintegrowanych segmentów rynków finansowych. Kurs wymiany dolara amerykańskiego względem złotego polskiego (USD/PLN) ma bezpośrednie znaczenie dla polskiej gospodarki: wpływa na koszty importu, wartość zobowiązań zadłużonych w walucie obcej oraz poziom inflacji importowanej. Instytucje finansowe, przedsiębiorstwa i inwestorzy indywidualni poszukują narzędzi wspierających podejmowanie decyzji na tym rynku, jednak prognozowanie kursów walutowych pozostaje zadaniem wyjątkowo trudnym.

Szeregi czasowe notowań finansowych charakteryzują się wysokim poziomem szumu, nieliniowością zależności oraz falowością rynku. Klasyczne modele ekonometryczne, oparte na założeniach stacjonarności i liniowości, często nie wystarczają do uchwycenia złożonych wzorców zachowania cen. W ostatnich latach coraz większą popularnością cieszą się metody uczenia głębokiego, w szczególności sieci rekurencyjne typu LSTM (Long Short-Term Memory) oraz architektury oparte na mechanizmie uwagi (attention), takie jak Transformer. Pozwalają one na modelowanie wielowymiarowych sekwencji czasowych i łączenie informacji z różnych horyzontów temporalnych.

Problem badawczy

Niniejsza praca podejmuje problem prognozowania kierunku zmiany kursu USD/PLN w horyzoncie 14 dni roboczych. Główne pytanie badawcze brzmi: *czy na podstawie 30-dniowej historii cech technicznych i makroekonomicznych można skutecznie przewidzieć, czy kurs wzrośnie, czy spadnie w ciągu kolejnych 14 dni?*

Punktem wyjścia jest skumulowany zwrot procentowy kursu zamknięcia w horyzoncie prognozy. Ze względu na praktyczną interpretację wyników (sygnały kupna i sprzedaży) zadanie sprowadzono do klasyfikacji binarnej: klasa 1 oznacza wzrost kursu, klasa 0 oznacza spadek. Etykieta dla dnia t definiowana jest jako:

$$y_t = \begin{cases} 1 & \text{gdy } \frac{P_{t+14}}{P_t} - 1 > 0, \\ 0 & \text{gdy } \frac{P_{t+14}}{P_t} - 1 \leq 0. \end{cases} \quad (1.1)$$

gdzie P_t oznacza kurs zamknięcia pary USD/PLN w dniu t .

Skumulowany zwrot w procentach wyraża się natomiast wzorem:

$$r_t = \left(\frac{P_{t+14}}{P_t} - 1 \right) \cdot 100\%. \quad (1.2)$$

Cel pracy

Celem pracy jest zaprojektowanie, implementacja i ocena hybrydowego modelu głębokiego łączącego warstwę LSTM z blokiem Transformer w zadaniu klasyfikacji kierunku kursu USD/PLN. W ramach realizacji celu:

- przygotowano wielowymiarowy zestaw cech obejmujący wskaźniki analizy technicznej oraz stopy procentowe banków centralnych (Fed, EBC, NBP),
- zbudowano i wytrenowano model na historycznych danych dziennych,
- oceniono skuteczność predykcji za pomocą metryk klasyfikacji (accuracy, precision, recall, F1) oraz porównano wyniki z prostymi benchmarkami (strategia „zawsze wzrost” i „zawsze spadek”).

Opis metody

Dane wejściowe

Analizie poddanoienne notowania z pliku `dane_ekonomiczne.csv`, którego źródłem jest Yahoo Finance oraz World Bank Data. Dane obejmują m.in. ceny OHLC pary USD/PLN, skorelowane pary walutowe (EUR/PLN, EUR/USD) oraz stopy procentowe banków centralnych Stanów Zjednoczonych, strefy euro i Polski. Z zestawu usunięto obserwacje przypadające na weekendy, aby zachować ciągłość danych sesyjnych. Przed przekazaniem do modelu wszystkie cechy numeryczne standaryzowano za pomocą `StandardScaler`, dopasowanego wyłącznie na zbiorze treningowym.

Inżynieria cech

Dla każdego dnia obliczono łącznie 24 zmienne wejściowe, w tym:

- dzienne stopy zwrotu kursów zamknięcia (USD/PLN, EUR/PLN, EUR/USD),
- wskaźniki momentum za okresy 3, 5 i 10 dni,
- RSI (14 okresów), ATR (14 okresów), pozycję i szerokość pasm Bollingera (okno 20 dni),
- wskaźniki MACD wraz z linią sygnałową i histogramem,
- zmienność krocząca, z-score (okno 20 dni), dzienny zakres High/Low oraz stosunek High/Low,
- stopy procentowe: US_FED, EA_ECB, PL_NBP,
- opóźnione kierunki zmian ceny (lagi 1, 2, 3 i 5 dni).

Architektura modelu

Model przyjmuje na wejściu sekwencję $X_t \in \mathbb{R}^{30 \times 24}$, tj. 30 kolejnych dni obserwacji po 24 cechy (okno przesuwne). Architektura hybrydowa składa się z następujących etapów:

1. warstwa LSTM z 128 jednostkami ukrytymi (`return_sequences=True`), wychwytyująca lokalne zależności czasowe w sekwencji,
2. warstwa Dropout ($p = 0,3$) redukująca przeuczenie,
3. kodowanie pozycyjne (*Positional Encoding*) nadające informację o położeniu obserwacji w oknie,
4. blok Transformer z 8 głowicami uwagi (*Multi-Head Attention*), $d_{\text{model}} = 128$ i warstwą sprzężeń zwrotnych o wymiarze 256, modelujący długoterminowe zależności w obrębie 30-dniowego okna,
5. agregacja `GlobalAveragePooling1D`, po której następują warstwy gęste (64 i 16 neuronów, aktywacja ReLU, regularyzacja L2) oraz warstwa wyjściowa z aktywacją sigmoid (jedna neurona, klasyfikacja binarna).

Połączenie LSTM i Transformera uzasadnia fakt, że sieć rekurencyjna efektywnie koduje krótkoterminowe wzorce cenowe, natomiast mechanizm self-attention pozwala ważyć znaczenie poszczególnych dni w historycznym oknie, co jest istotne przy analizie wielotygodniowych trendów.

Trenowanie i ewaluacja

Dane podzielono chronologicznie: 80 % stanowi zbiór treningowy, 20 % — testowy. Z części treningowej wydzielono 10 % obserwacji na walidację. Ze względu na naturę szeregu czasowego podczas uczenia nie stosowano losowego mieszania próbek (`shuffle=False`).

Model trenowano algorytmem Adam z początkową szybkością uczenia 10^{-5} , funkcją straty `binary_crossentropy` oraz wagami klas (`compute_class_weight`) kompensującymi niezbalansowanie etykiet. Zastosowano wczesne zatrzymanie (*early stopping*) monitorujące dokładność walidacyjną oraz redukcję szybkości uczenia przy stagnacji straty. Predykcje ciągłe z warstwy sigmoid konwertowano na klasy za pomocą progu 0,5.

Jakość modelu oceniano metrykami: accuracy, precision, recall, F1 oraz macierzą pomyłek. Wyniki porównywano z naiwnymi strategiami bazowymi przewidującymi zawsze wzrost lub zawsze spadek kursu.

Zakres i ograniczenia

Praca koncentruje się wyłącznie na prognozie *kierunku* zmiany ceny, a nie na estymacji jej poziomu ani wielkości zwrotu. Nie uwzględniono kosztów transakcyjnych, spreadu bid-ask ani dźwigni finansowej, co ogranicza bezpośrednią aplikowalność wyników w realnym handlu algorytmicznym.

Model wytrenowano na danych historycznych z okresu od 2020 roku do 2024 roku; jego skuteczność w przyszłości nie jest gwarantowana ze względu na ryzyko przeuczenia oraz falowość rynku. Wyników nie należy traktować jako rekomendację inwestycyjną.

Rozdział 2

Teoria

2.1 Szeregi czasowe finansowe

Notowania instrumentów finansowych tworzą szereg czasowy — uporządkowany ciąg obserwacji, w którym kolejność ma znaczenie predykcyjne. Kurs walutowy USD/PLN jest procesem o wysokiej zmienności.

Mimo tego w danych historycznych można zaobserwować krótkoterminowe zależności korelacyjne, które stanowią podstawę analizy technicznej i modeli uczących się.

2.2 Sieci LSTM

LSTM (Long Short-Term Memory) to architektura rekurencyjnej sieci neuronowej (RNN), zaproponowana przez Hochreitera i Schmidhubera w 1997 roku.

W przeciwieństwie do klasycznego RNN, LSTM rozwiązuje problem zanikającego gradientu dzięki komórce pamięci i bramkom: wejścia (*input*), zapomnienia (*forget*) oraz wyjścia (*output*).

W projekcie warstwa LSTM z 128 jednostkami ukrytymi koduje lokalne wzorce cenowe z 30-dniowego okna obserwacji.

2.3 Architektura Transformer i mechanizm uwagi

Transformer, wprowadzony przez Vaswaniego (2017), opiera się na mechanizmie *self-attention*, który pozwala każdemu elementowi sekwencji ważyć znaczenie pozostałych.

W implementacji (`TransformerBlock`) zastosowano wielogłowicową uwagę (*Multi-Head Attention*, 8 głów) oraz kodowanie pozycyjne sinusoidalne (`PositionalEncoding`), które nadaje informację o położeniu dnia w oknie czasowym.

Połączenie LSTM + Transformer pozwala jednocześnie modelować krótkoterminową dynamikę oraz długoterminowe zależności w obrębie 30 dni.

2.4 Dane wejściowe modelu

Model przyjmuje sekwencję 30×24 : 30 kolejnych dni sesyjnych, po 24 zmienne w każdym dniu. Poniżej opisano wszystkie cechy używane w pliku `LSTM.py`.

2.4.1 Notowania walutowe (stopy zwrotu)

- `Close_USDPLN` — dzienna stopa zwrotu pary USD/PLN, liczona jako `pct_change` ceny zamknięcia; główny instrument prognozy.
- `Close_EURPLN` — dzienna stopa zwrotu EUR/PLN liczona jako `pct_change` ceny zamknięcia.
- `Close_EURUSD` — dzienna stopa zwrotu EUR/USD liczona jako `pct_change` ceny zamknięcia.

2.4.2 Momentum

Trzy wskaźniki tempa zmiany ceny USD/PLN, liczone na surowej cenie zamknięcia (`pct_change` za n dni):

- `mom_3` — momentum 3-dniowe,
- `mom_5` — momentum 5-dniowe,
- `mom_10` — momentum 10-dniowe.

2.4.3 Wskaźniki techniczne

- `RSI` (okno 14) — Relative Strength Index; wartość 0–100, opisuje siłę ostatnich wzrostów względem spadków.
- `ATR` (okno 14) — Average True Range; średni dzienny zakres cenowy, miara zmienności.
- `bb_pos` (okno 20) — pozycja ceny względem pasm Bollingera: $(P_t - MA_{20})/\sigma_{20}$.
- `bb_width` (okno 20) — szerokość pasm Bollingera: $2\sigma_{20}/MA_{20}$.
- `MACD` — różnica EMA(okno 12) i EMA(okno 26) ceny zamknięcia.
- `MACD_signal` — EMA(okno 9) linii MACD.
- `MACD_histogram` — różnica MACD i linii sygnałowej.
- `usd_volatility` (okno 10) — odchylenie standardowe dziennych stóp zwrotu USD/PLN.
- `zscore_20` — z -score ceny zamknięcia w 20-dniowym oknie kroczącym.

2.4.4 Cechy z zakresu High/Low (USD/PLN)

Liczone z oryginalnych notowań OHLC, przed konwersją ceny na stopę zwrotu:

- `usd_daily_range` — względny dzienny zakres: $(High - Low)/Close$,
- `usd_hl_ratio` — stosunek High/Low.

2.4.5 Stopy procentowe banków centralnych

Dane makroekonomiczne z pliku `dane_ekonomiczne.csv` (źródła: Yahoo Finance, World Bank Data):

- `US_FED` — stopa procentowa Rezerwy Federalnej Stanów Zjednoczonych,
- `EA_ECB` — stopa Europejskiego Banku Centralnego (strefa euro),
- `PL_NBP` — stopa Narodowego Banku Polskiego.

2.4.6 Opóźniony kierunek zmiany ceny

Cztery cechy binarne/znakowe opisujące kierunek dziennej zmiany ceny USD/PLN w poprzednich dniach (`sign(pct_change)` z opóźnieniem):

- `dir_lag_1` — kierunek sprzed 1 dnia,
- `dir_lag_2` — kierunek sprzed 2 dni,
- `dir_lag_3` — kierunek sprzed 3 dni,
- `dir_lag_5` — kierunek sprzed 5 dni.

2.4.7 Preprocessing przed wejściem do sieci

Wszystkie 24 cechy przechodzą standaryzację `StandardScaler` (dopasowanie μ i σ wyłącznie na zbiorze treningowym). Następnie budowane są okna przesuwne długości 30 dni, które trafiają do warstwy wejściowej modelu LSTM.

2.5 Zadanie klasyfikacji binarnej

Zamiast prognozować dokładną wartość kursu, model przewiduje *kierunek* zmiany w horyzoncie $H = 14$ dni roboczych. Etykieta definiowana jest jako:

$$y_t = \begin{cases} 1 & \text{gd}y \frac{P_{t+14}}{P_t} - 1 > 0, \\ 0 & \text{gd}y \frac{P_{t+14}}{P_t} - 1 \leq 0. \end{cases} \quad (2.1)$$

gdzie P_t to kurs zamknięcia USD/PLN. Klasa 1 oznacza wzrost (sygnał LONG/KUP), klasa 0 — spadek (sygnał SHORT/SPRZEDAJ).

Rozdział 3

Opis działania aplikacji

3.1 Uwagi przed uruchomieniem

- Skrypt `LSTM.py` wymaga pliku `dane_ekonomiczne.csv` w tym samym katalogu co skrypt. Można go pobrać skryptem `main_gui.py`.
- Zalecane środowisko: Python 3.10+, TensorFlow 2.x, pandas, scikit-learn, matplotlib.
- Ze względu na losowość inicjalizacji wag sieci ustawiono stałe ziarno (`SEED = 42`) dla powtarzalności wyników.

3.2 O aplikacji

Aplikacja została napisana w języku Python z wykorzystaniem biblioteki TensorFlow/Keras.

Główny plik implementacyjny to `LSTM.py`. Powiązane pliki w repozytorium:

- `DataDownloader.py` — pobieranie danych z Yahoo Finance i World Bank,
- `DataTransformer.py` — transformacja danych do formatu dziennego,
- `main_gui.py` — Plik z funkcjami gui do pobierania i wizualizacji danych.

3.3 Przepływ danych

Schemat przetwarzania danych w `LSTM.py`:

1. Wczytanie `dane_ekonomiczne.csv`.
2. Usunięcie zbędnych kolumn i weekendów.
3. Obliczenie 24 cech technicznych i makroekonomicznych.
4. Usunięcie wierszy z wartościami NaN
5. Podział chronologiczny 80 % / 20 % (trening / test).

6. Standaryzacja `StandardScaler`
7. Budowa okien przesuwnych 30×24 .
8. Trenowanie modelu, predykcja, ewaluacja metryk.

3.4 Parametry konfiguracyjne

Tabela 3.1 zestawia główne hiperparametry modelu.

Tabela 3.1: Hiperparametry modelu w `LSTM.py`

Parametr	Wartość	Opis
<code>sliding_window</code>	30	Długość okna wejściowego (dni)
<code>prediction_horizon</code>	14	Horyzont prognozy (dni)
<code>num_of_epochs</code>	50	Maksymalna liczba epok
<code>LSTM units</code>	128	Jednostki ukryte warstwy LSTM
<code>num_heads</code>	8	Liczba głów uwagi w Transformer
<code>embed_dim</code>	128	Wymiar osadzenia
<code>ff_dim</code>	256	Wymiar warstwy FFN
<code>Dropout</code>	0.3 / 0.5 / 0.3	Po LSTM / Dense64 / Dense16
<code>Learning rate</code>	5×10^{-5}	Szybkość uczenia (Adam)
<code>Batch size</code>	16	Rozmiar minibatcha
<code>Podział train/test</code>	80 % / 20 %	Chronologiczny
<code>Podział train/val</code>	90 % / 10 %	Z części treningowej
<code>Próg klasyfikacji</code>	0.5	Konwersja sigmoid $\rightarrow$ klasa

3.5 Architektura modelu

Model hybrydowy składa się z następujących warstw (kolejność w `LSTM.py`):

- **Wejście:** `Input(shape=(30, 24))` — 30 dni historii, 24 cechy na dzień
- **`LSTM(128, return_sequences=True)`** — warstwa rekurencyjna, 128 jednostek ukrytych, zwraca całą sekwencję
- **`Dropout(0.3)`** — regularyzacja
- **`PositionalEncoding(max_len=30, embed_dim=128)`** — kodowanie pozycji dni w oknie
- **`TransformerBlock(embed_dim=128, num_heads=8, ff_dim=256)`** — blok uwagi, 8 głów, wymiar 128, warstwa FFN o rozmiarze 256
- **`GlobalAveragePooling1D()`** — agregacja sekwencji do jednego wektora
- **`Dense(64, relu, L2=0.005)`** — warstwa gęsta, 64 neurony, aktywacja ReLU, regularyzacja L2
- **`Dropout(0.5)`**

- **Dense(16, relu, L2=0.005)** — warstwa gęsta, 16 neuronów
- **Dropout(0.3)**
- **Dense(1, sigmoid)** — wyjście binarne (prawdopodobieństwo wzrostu)

Funkcja straty: `binary_crossentropy`.

Optymalizator: Adam z `ReduceLROnPlateau` i `EarlyStopping` (monitorowanie `val_accuracy`, `patience=50`).

3.6 Interpretacja wyników

Program wypisuje następujące sekcje (funkcje pomocnicze na końcu pliku):

- **Class balance** — procent klas UP/DOWN w zbiorze treningowym.
- **Class weights** — wagi kompensujące niezbalansowanie.
- **Tabela wyników** — data, cena, rzeczywisty i przewidziany kierunek.
- **Macierz błędu** — TP, TN, FP, FN.
- **Metryki** — accuracy, precision, recall, F1.
- **Benchmark** — porównanie z strategiami „zawsze LONG” i „zawsze SHORT”.
- **Wykres** — notowania USD/PLN z oznaczeniem sygnałów (zielone $\wedge$ = KUP, czerwone $\vee$ = SPRZEDAJ).

Rozdział 4

Badania modelu

4.1 Wprowadzenie

W rozdziale przedstawiono wyniki testów modelu LSTM + Transformer w zadaniu klasyfikacji kierunku kursu USD/PLN (horyzont 14 dni). Najpierw opisano konfigurację referencyjną i wyniki uruchomienia bazowego, następnie plan pięciu eksperymentów (E1–E5), w których zmieniano **wyłącznie jeden** hiperparametr na raz.

4.2 Konfiguracja bazowa

Konfiguracja referencyjna odpowiada domyślnym ustawieniom w pliku LSTM.py.

Tabela 4.1: Parametry konfiguracji referencyjnej

Parametr	Wartość
sliding_window	30
prediction_horizon	14
Jednostki LSTM	128
embed_dim	128
num_heads	8
ff_dim	256
Learning rate (Adam)	10^{-5}
Dropout (LSTM / Dense64 / Dense16)	0.3 / 0.5 / 0.3
batch_size	16
num_of_epochs	50
Podział train / test	80 % / 20 %
shuffle	False
SEED	42

4.3 Wyniki konfiguracji bazowej

Model oceniono na zbiorze testowym stanowiącym ostatnie 20 % obserwacji. Poniżej zestawiono wybrane predykcje, macierz pomyłek, metryki klasyfikacji oraz porównanie z benchmarkami.

4.3.1 Macierz pomyłek

Tabela 4.2: Macierz pomyłek — konfiguracja bazowa

Kategoria	Liczba
TP (trafione wzrosty)	110
TN (trafione spadki)	45
FP (fałszywe wzrosty)	64
FN (fałszywe spadki)	22

4.3.2 Metryki klasyfikacji i benchmark

Tabela 4.3: Metryki modelu i strategii porównawczych

Metryka	Wartość
Accuracy	64,32 %
Precision	63,22 %
Recall	83,33 %
F1 Score	71,90 %
Model LSTM + Transformer	64,32 %
Strategia „zawsze LONG”	54,77 %
Strategia „zawsze SHORT”	45,23 %

4.3.3 Interpretacja wyników

Model osiągnął accuracy 64,32 % i $F1 = 71,90\%$, przewyższając benchmark „zawsze LONG” (54,77 %). Oznacza to, że hybryda LSTM + Transformer wnosi wartość predykcyjną wykraczającą poza prostą strategię bazową. Wysoki recall (83,33 %) wskazuje, że model wykrywa większość rzeczywistych wzrostów kursu (110 z 132 przypadków klasy UP). Precision na poziomie 63,22 % oznacza natomiast, że część sygnałów kupna okazuje się fałszywa (64 przypadki FP). Model ma zatem tendencję do częstszego przewidywania wzrostów, co przy horyzoncie 14 dni może wynikać z asymetrii nagród za trafione wzrosty w zbiorze testowym. Na zbiorze testowym (241 obserwacji) model poprawnie sklasyfikował 155 przypadków (64,32 %). Błędy rozkładają się nierównomiernie: fałszywe wzrosty ($FP = 64$) występują częściej niż fałszywe spadki ($FN = 22$), co potwierdza przewagę prognoz kierunku „góra” nad „dół”. Ze względu na lekko większy udział klasy DOWN w danych treningowych (53,5 %) zastosowano wagi klas ($DOWN = 0,93$, $UP = 1,08$), co mogło przyczynić się do poprawy czułości na wzrosty bez istotnej utraty ogólnej accuracy.

4.4 Eksperymenty ze zmianą parametrów

W dalszej części badań testowano wpływ pojedynczych hiperparametrów. Każdy eksperyment obejmował trzy wartości parametru. Pozostałe ustawienia pozostawiano jak w konfiguracji bazowej.

Tabela 4.4: Plan eksperymentów

Eksperyment	Parametr	Testowane wartości
E1	sliding_window	14, 45, 60
E2	num_heads	4, 12, 16
E3	Learning rate	0.0001, 0.00005, 0.000005
E4	Dropout (wszystkie warstwy)	0.2, 0.3, 0.5

E1 — długość okna historycznego widocznego dla modelu

E2 — liczba głów mechanizmu uwagi w bloku Transformer.

E3 — szybkość uczenia optymalizatora Adam.

E4 — siła regularyzacji dropout taka sama we wszystkich warstwach
Dropout stosowano tę samą wartość testową.

4.5 Wyniki eksperymentów

4.5.1 E1 — wpływ sliding_window

Tabela 4.5: Wyniki eksperymentu E1

Okno	Acc.	Prec.	Rec.	F1	vs LONG
14	49,79	53,64	61,36	61,36	gorszy
45	60,58	60,45	81,06	69,26	lepsy
60	61.83	59.01	99.24	74.01	lepsy

4.5.2 E2 — wpływ num_heads

Tabela 4.6: Wyniki eksperymentu E2

Głowy	Acc.	Prec.	Rec.	F1	vs LONG
4	63,49	66,92	65,91	66,41	lepsy
12	58,09	60,69	66,67	63,54	lepsy
16	64,73	64,60	78,79	70,99	lepsy

4.5.3 E3 — wpływ learning rate

Tabela 4.7: Wyniki eksperymentu E3

LR	Acc.	Prec.	Rec.	F1	vs LONG
0.0001	58,92	60,78	70,45	65,26	lepsy
0.00005	57,68	56,41	100,00	72,13	lepsy
0.000005	59,75	62,59	65,91	64,21	lepsy

4.5.4 E4 — wpływ dropout

Tabela 4.8: Wyniki eksperymentu E4

Dropout	Acc.	Prec.	Rec.	F1	vs LONG
0.2	63,07	62,72	80,30	70,43	lepszy
0.3	63,49	60,89	93,18	73,65	lepszy
0.5	64,73	61,69	93,94	74,47	

Rozdział 5

Wnioski

5.1 Podsumowanie badań

Przeprowadzono serię czterech eksperymentów, w których zmieniano pojedynczy hiperparametr modelu, pozostawiając pozostałe ustawienia zgodne z konfiguracją bazową. Benchmarkiem porównawczym była strategia „zawsze LONG” (accuracy = 54,77 %). We wszystkich wariantach poza jednym model przewyższał ten próg, co potwierdza sens zastosowania uczenia głębokiego w tym zadaniu. Najlepszy wynik we wszystkich badaniach uzyskano dla **dropout** = 0,5: F1 = 74,47 %, accuracy = 64,73 %.

5.2 Wnioski z poszczególnych eksperymentów

5.2.1 E1 — długość okna sliding_window

Zmiana długości okna historycznego miała największy wpływ na jakość predykcji. Najkrótsze okno (14 dni) dało najgorszy wynik: accuracy 49,79 % i F1 = 61,36 %, poniżej benchmarku „zawsze LONG”. Model nie miał wystarczająco dużo kontekstu, by uchwycić dynamikę kursu w 14-dniowym horyzoncie prognozy. Okna 45 i 60 dni przyniosły wyraźną poprawę (F1 = 69,26 % i 74,01 %). Najlepszy wariant w tym eksperymencie to **okno 60 dni** (accuracy 61,83 %). Wskazuje to, że przy prognozie kierunku na 14 dni korzystniejsza jest dłuższa historia cenowa niż bardzo krótkie okno.

5.2.2 E2 — liczba głów uwagi num_heads

Wzrost liczby głów mechanizmu attention nie zawsze poprawiał wyniki. Wariant z 4 głowami osiągnął F1 = 66,41 %, wariant z 12 głowami okazał się słabszy (F1 = 63,54 %), co oznacza, że większa liczba głów nie ma tak znaczącego wpływu na wyniki.

5.2.3 E3 — szybkość uczenia (learning rate)

Wszystkie trzy testowane wartości learning rate przewyższyły benchmark. Najwyższe F1 (72,13 %) uzyskano przy **lr** = 0,00005, jednak przy tej wartości recall wyniósł 100 % co oznacza, że model przewidywał prawie wyłącznie wzrosty. Taki wynik jest mylący ponieważ wysoki F1 wynika głównie z dominacji klasy UP w zbiorze testowym, a nie z precyzyjnej klasyfikacji. Bardziej zrównoważony kompromis precision/recall daje **lr** =

0,0001. Zbyt mała szybkość spowalnia uczenie bez wyraźnej poprawy nad pozostałymi wariantami.

5.2.4 E4 — współczynnik dropout

Zwiększanie dropout miało pozytywny wpływ na jakość modelu. Wraz ze wzrostem dropoutu rosło F1. Wyższy dropout ogranicza przeuczenie i poprawia generalizację na zbiorze testowym, przy jednoczesnym utrzymaniu wysokiego recall (93,94 % przy dropout 0,5).

5.3 Wnioski ogólne

1. Model LSTM + Transformer w konfiguracji bazowej i w wariantach eksperymentalnych przewyższa prostą strategię „zawsze LONG”, z wyjątkiem bardzo krótkiego okna (14 dni).
2. Najważniejszym parametrem okazała się **długość okna czasowego**: zbyt krótkie okno drastycznie pogarsza wyniki.
3. **Dropout 0,5** dał najlepsze F1 we wszystkich badaniach (74,47 %).
4. **16 głów uwagi** w Transformerze daje najlepszy wynik w E2.
5. Recall bliski 100 % (E3, lr = 0,00005) nie należy traktować jako sukces — oznacza dominację jednej klasy w predykcjach. Przy ocenie modelu należy patrzeć łącznie na F1, precision i macierz pomyłek.
6. Przy połączeniu najlepszych hiperparametrów uzyskanych w wyniku badań: `sliding_window` = 60, `num_heads` = 16, learning rate = 0,0001, dropout = 0,5 model uzyskał gorszy wynik niż „zawsze LONG” (Recall wynosił 61,36 % , F1 wynosiło 55,48 % Accuracy wynosiło 46,06 %). Oznacza to, że poprawa niektórych hiperparametrów przy połączeniu nie zawsze przynosi pozytywny efekt.

5.4 Ograniczenia

Model uczy się wyłącznie na danych ekonometrycznych, więc nie jest w stanie właściwie zareagować na nagłe zmiany na rynku finansowym lub wydarzenia geopolityczne. Wyniki nie uwzględniają kosztów transakcji, ponieważ przy danej architekturze model powielałby ostatnie znane wartości, minimalizując w ten sposób funkcję straty. Dane na których operowałem są zbyt ograniczone by zaobserwować pełną cykliczność rynku. Wysoki recall przy niektórych konfiguracjach sugeruje tendencję modelu do częstszego generowania sygnałów kupna, co jest związane z trendem rosnącym w danym przedziale czasowym. Daną architekturę modelu należy traktować jedynie jako element badań naukowych, **nie należy używać go jako źródło porad inwestycyjnych**.

5.4.1 Repozytorium projektu

Kod źródłowy znajduje się pod adresem:

<https://github.com/jakjan777/PredykcjaForex>

Bibliografia

1. Hochreiter S., Schmidhuber J.,
Long Short-Term Memory,
Neural Computation, 9(8), 1735–1780, 1997.
2. Vaswani A., Shazeer N., Parmar N., *et al.*,
Attention Is All You Need,
Advances in Neural Information Processing Systems, 2017.
3. Dokumentacja TensorFlow/Keras:
https://www.tensorflow.org/api_docs/python/tf/keras
4. Dokumentacja scikit-learn (metryki klasyfikacji):
https://scikit-learn.org/stable/modules/model_evaluation.html